Avito

ФИНАЛ ХАКАТОНА АВИТО

2025

Хакатон Avito

Как предсказать спад органического трафика и продать VAS вовремя

Команда:

Кронверкские псы

БИЗНЕС-ПРОБЛЕМА

Стратегия VAS: Каннибализация трафика vs Упущенная выгода

Если пушим ВСЕХ сразу

Горячие машины продадутся сами

Высоколиквидные авто получают 50+ органических обращений в день. Навязывание платных услуг при такой конверсии ведет к негативу пользователей и репутационным рискам.

Каннибализация бесплатной органики

Клиент платит за сделки, которые состоялись бы органически без применения VAS. Это обесценивает услугу в глазах пользователя и снижает метрики доверия.

Отток лояльных клиентов

Осознание нецелесообразности трат ведет к переходу продавцов на платформы конкурентов (Дром, Юла, Авто.ру). При этом стоимость привлечения нового пользователя запрашивает допольнительных ресурсов.

Игнорирование «зависших» объявлений)

Месяц без звонков = отток на конкурентов

Длительная экспозиция без обращений снижает лояльность продавца к площадке. В результате платформа теряет активного пользователя.

Деградация инвентаря

Неактуальные объявления засоряют поиск: покупателям сложнее найти подходящее авто, из-за чего падает конверсия и портится впечатление от площадки.

Упущенная выручка

Если машина не продается 30+ дней готовность продавца к покупке платных инструментов максимальна. Бездействие приводит к потере выручки в момент пиковой мотивации клиента..

ЦЕЛЬ: Определить точку перегиба (Окно конверсии)

Найти временной интервал, в котором органический трафик уже исчерпан, но объявление еще актуально. Это оптимальное окно для предложения VAS: потребность продавца максимальна, а лояльность еще не утрачена.

Анатомия сырых данных: шум, фейки и 11% корреляции

Очистка от шума

Отсечение выбросов по 0.5-му и 99.5-му перцентилям (тестовые объявления, аномальные цены). Восстановление пропусков (IMV) через медианы узких когорт (марка + модель + год + регион).

Матрица корреляций Пирсона

Влияние изолированных факторов (цена, пробег, год, регион) на ликвидность минимально. Максимальный коэффициент корреляции Пирсона не превышает 0.11. Ни один из базовых параметров в одиночку не способен объяснить скорость продажи из-за высокой фрагментации рынка.

ВЫВОД: Линейной зависимости нет

Стандартные методы регрессии здесь неэффективны. Если отдельные факторы объясняют всего **~1.2%** дисперсии — необходима кластеризация и нелинейные модели. Мы должны искать скрытые паттерны в комбинациях признаков, а не полагаться на корреляцию простых величин.

0.5-99.5%
Перцентили для очистки

0.11
Макс. корреляция

Когорты
Восстановление IMV

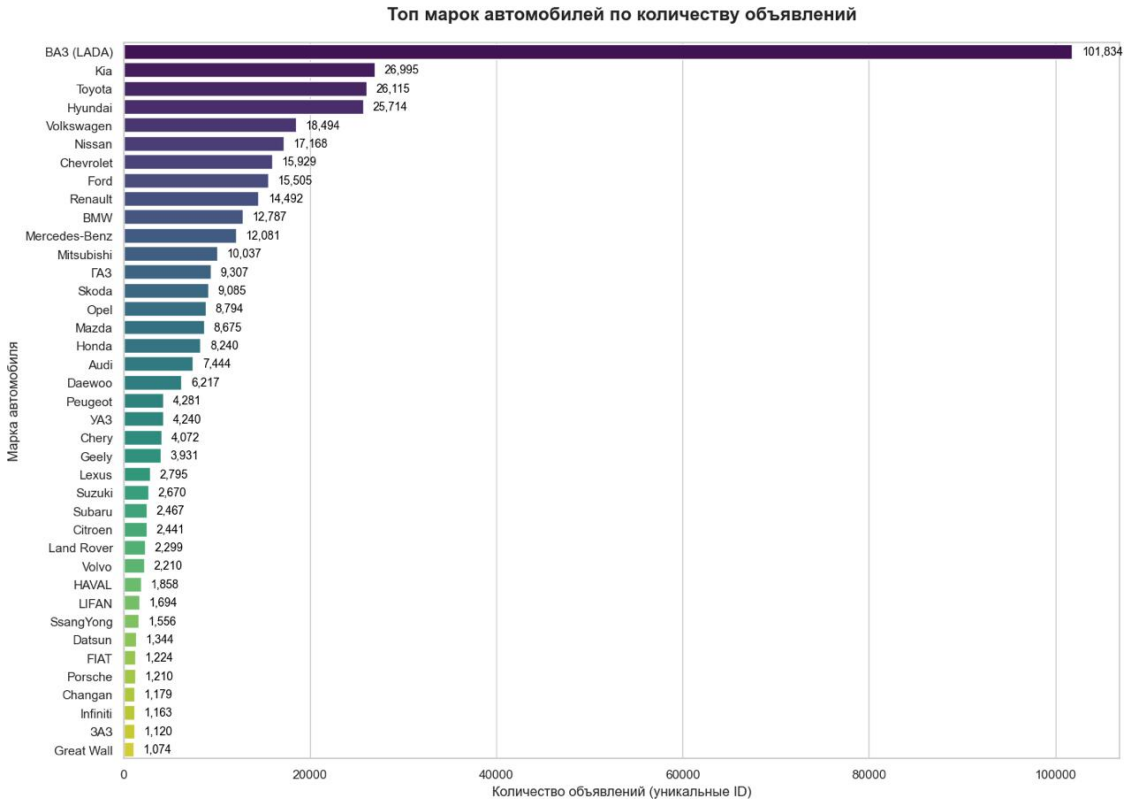
Топ марок автомобилей по количеству объявлений
ВАЗ (LADA) 101,834
Kia 26,995
Toyota 26,115
Hyundai 25,714
Volkswagen 18,494
Nissan 17,168
Chevrolet 15,929
Ford 15,505
Renault 14,492
BMW 12,787
Mercedes-Benz 12,081
Mitsubishi 10,037
ГАЗ 9,307
Skoda 9,085
Opel 8,794
Mazda 8,675
Honda 8,240
Audi 7,444
Daewoo 6,217
Peugeot 4,281
УАЗ 4,240
Chery 4,072
Geely 3,931
Lexus 2,795
Suzuki 2,670
Subaru 2,467
Citroen 2,441
Land Rover 2,299
Volvo 2,210
HAVAL 1,858
LIFAN 1,694
SsangYong 1,556
Datsun 1,344
FIAT 1,224
Porsche 1,210
Changan 1,179
Infiniti 1,163
ЗАЗ 1,120
Great Wall 1,074
Марка автомобиля
0
20000
40000
60000
80000
100000
Количество объявлений (уникальные ID)

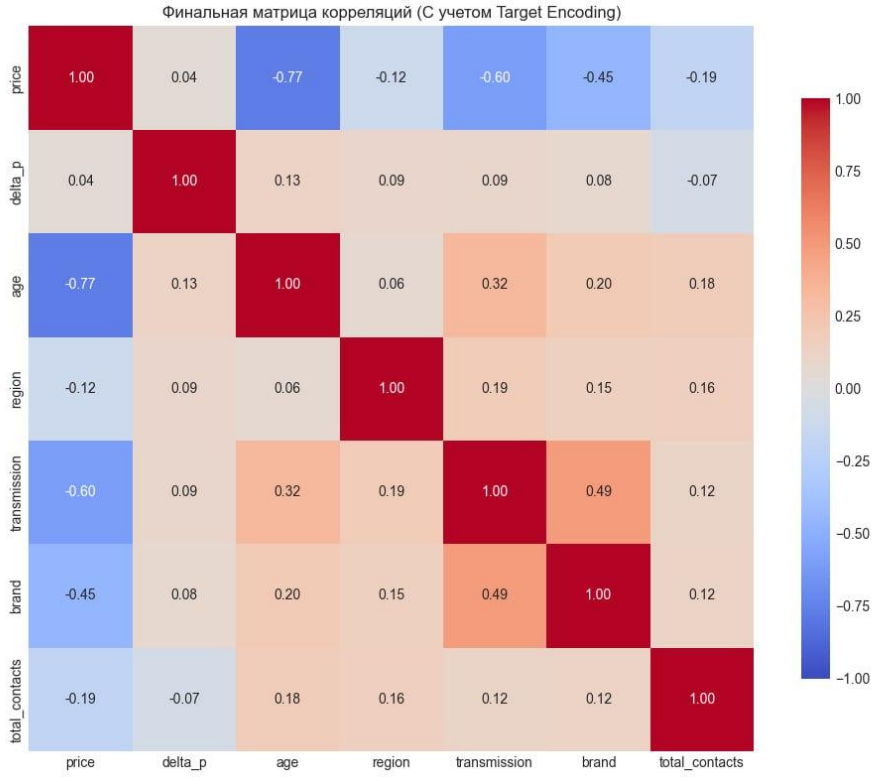
Финальная матрица корреляций (С учетом Target Encoding)
price 1.00 0.04 -0.77 -0.12 -0.60 -0.45 -0.19
delta_p 0.04 1.00 0.13 0.09 0.09 0.08 -0.07
age -0.77 0.13 1.00 0.06 0.32 0.20 0.18
region -0.12 0.09 0.06 1.00 0.19 0.15 0.16
transmission -0.60 0.09 0.32 0.19 1.00 0.49 0.12
brand -0.45 0.08 0.20 0.15 0.49 1.00 0.12
total_contacts -0.19 -0.07 0.18 0.16 0.12 0.12 1.00
price delta_p age region transmission brand total_contacts
1.00
0.75
0.50
0.25
0.00
−0.25
−0.50
−0.75
−1.00

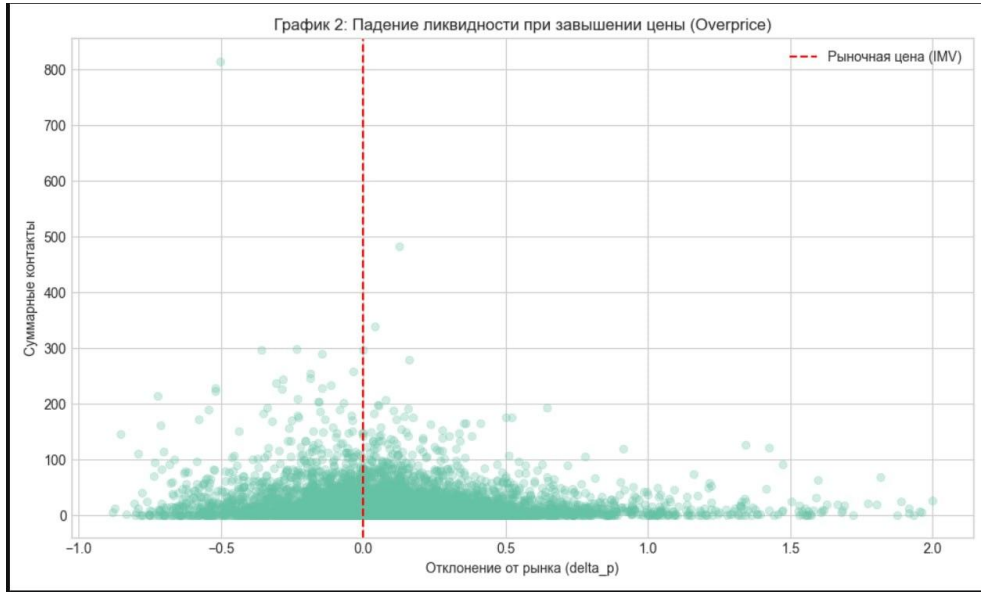
График 2: Падение ликвидности при завышении цены (Overprice)
Рыночная цена (IMV)
Суммарные контакты
0
100
200
300
400
500
600
700
800
−1.0
−0.5
0.0
0.5
1.0
1.5
2.0
Отклонение от рынка (delta_p)

Комбинаторная сегментация: Поиск скрытых взаимодействий

$C_6^3 = 20$

комбинаций

Гипотеза: Одиночный признак (цена или пробег) не объясняет продажу. Ликвидность — это не свойство машины, это **свойство контекста**. Мы ищем «химию» между признаками.

Метод

- **6 базовых фичей:** Марка, Модель, Год, Пробег, Регион, Цена
- **Все сочетания по 3:** $C_6^3 = 20$ комбинаций

```
// Пример комбинации
[Марка, Модель] +
[Возраст] +
[Регион]
```

Логика

1 фактор	r = 0.11
2 фактора	r = 0.18
3 фактора	**«Золотая середина»**

Тройка признаков — сегмент достаточно крупен для статистики, но уже четко описывает уникальное поведение покупателя

Инновация

Feature Interaction Map:

Мы не просто делим базу — мы ищем комбинации, где дисперсия минимальна

```
// Алгоритм поиска
FOR combo IN combinations:
    segment = filter(data, combo)
    variance = calc_variance(
        segment.time_to_sell
    )
    IF variance < threshold:
        // Монолитный сегмент
        save(segment)
```

Кейс: Toyota Camry + 5 лет + Регион

Москва
3.2 дня
Медиана продажи

Дальний Восток
12.8 дней
Медиана продажи

↓ Ликвидность падает в 4 раза при смене региона

Оптимизация признакового пространства: От хаоса к 30 бизнес-сегментам

Проблема: 85 регионов и 500+ сочетаний марок/моделей — это математический «шум». Обучать модель на таком количестве категорий — значит ловить случайные флуктуации.

Гео-кластеры (12 групп)

Мы объединили регионы не по географии, а по паттернам спроса

Кавказ	Приоритет Lada
Москва/Питер	Премиум-ликвидность
Сибирь	Японский масс-маркет

Кластеризация по корреляции спроса, а не расстоянию между городами

Бренд-кластеры (8 групп)

Кластеризация по объему объявлений и скорости выгорания органики

«Китайский экспресс» HOT

Haval, Chery — самый динамичный сегмент 2024-2025

Премиум-японцы	Toyota, Lexus
Масс-маркет	Lada, Kia, Hyundai

Математический фильтр: Поправка Холма-Бонферрони

Коррекция для множественной проверки гипотез

Потенциальных комбинаций

$12 \times 8 = 96$ → Статистически значимых **30** | Отсечено (шум) **66**

Мы не «схлопнули» данные — мы убрали ложные корреляции, оставив только устойчивые сегменты

Архитектура 30 сегментов:
Где органика «живет», а где «умирает»

Принцип монолитности: Внутри каждого сегмента поведение пользователей идентично. Ошибка предсказания времени продажи внутри сегмента **в 5 раз ниже**, чем по всей базе.

Tier 1: Горячие

10 сегментов

Органика справляется сама. Предлагать VAS здесь — значит **злить клиента** и терять репутацию

Пример:

Lada Granta в Поволжье

1.5 дня

Медиана продажи

Не вмешиваться

Tier 2: Средние

10 сегментов

Зона борьбы. Органика дает **80% лидов за первую неделю**, затем «затухает»

Стратегия:

VAS как инструмент дожима

Запускать на 7-й день

Точечное вмешательство

Tier 3: Висяки

10 сегментов

«Висяки». Без платного продвижения **шансы на продажу стремятся к нулю**

Пример:

BMW 7-series, 200к+ пробег

45 дней

Медиана продажи

Агрессивное продвижение

Золотая метрика

Разница в ликвидности между Tier-1 и Tier-3

37 раз

Одна общая стратегия пушей для этих групп — это **маркетинговое самоубийство**

Наша модель дает **30 разных стратегий** для 30 сегментов

Полярность спроса: Где органика работает сама, а где критически необходим VAS

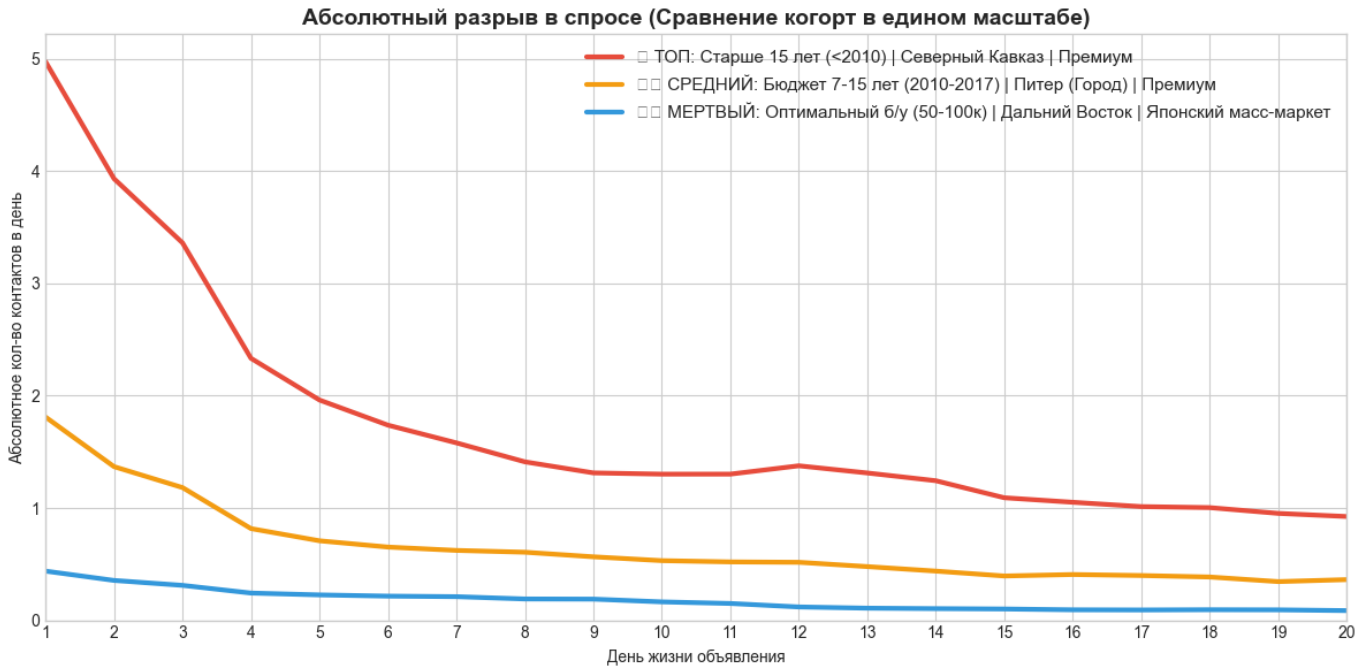

Горячие ниши (Зона высокой органики):
Профиль: Старше 15 лет (<2010) | Северный Кавказ | Премиум.
Инсайт: Лоты стабильно собирают по 14–18 контактов в день. Этим объявлениям платные услуги продвижения не нужны — они продают себя сами за счет высокого регионального спроса на данный класс авто.

Мертвые ниши (Зона обязательного внедрения VAS):
Профиль: Комфорт (600к-1.5м) | Свежее авто (0-50к) | Дальний Восток.
Инсайт: Медиана ликвидности равна нулю. Пользователи игнорируют эти лоты, и без раннего агрессивного предложения VAS они просто «осядут на складах».

Базлайн (Норма рынка):
Профиль: 7-15 лет | Санкт-Петербург | Премиум
Инсайт: Типичный масс-маркет с умеренным спросом. Здесь стратегия продвижения должна балансировать между органической видимостью и точечным предложением услуг при падении контактов.

Непараметрический анализ категорий ликвидности: распределение и структурные сдвиги

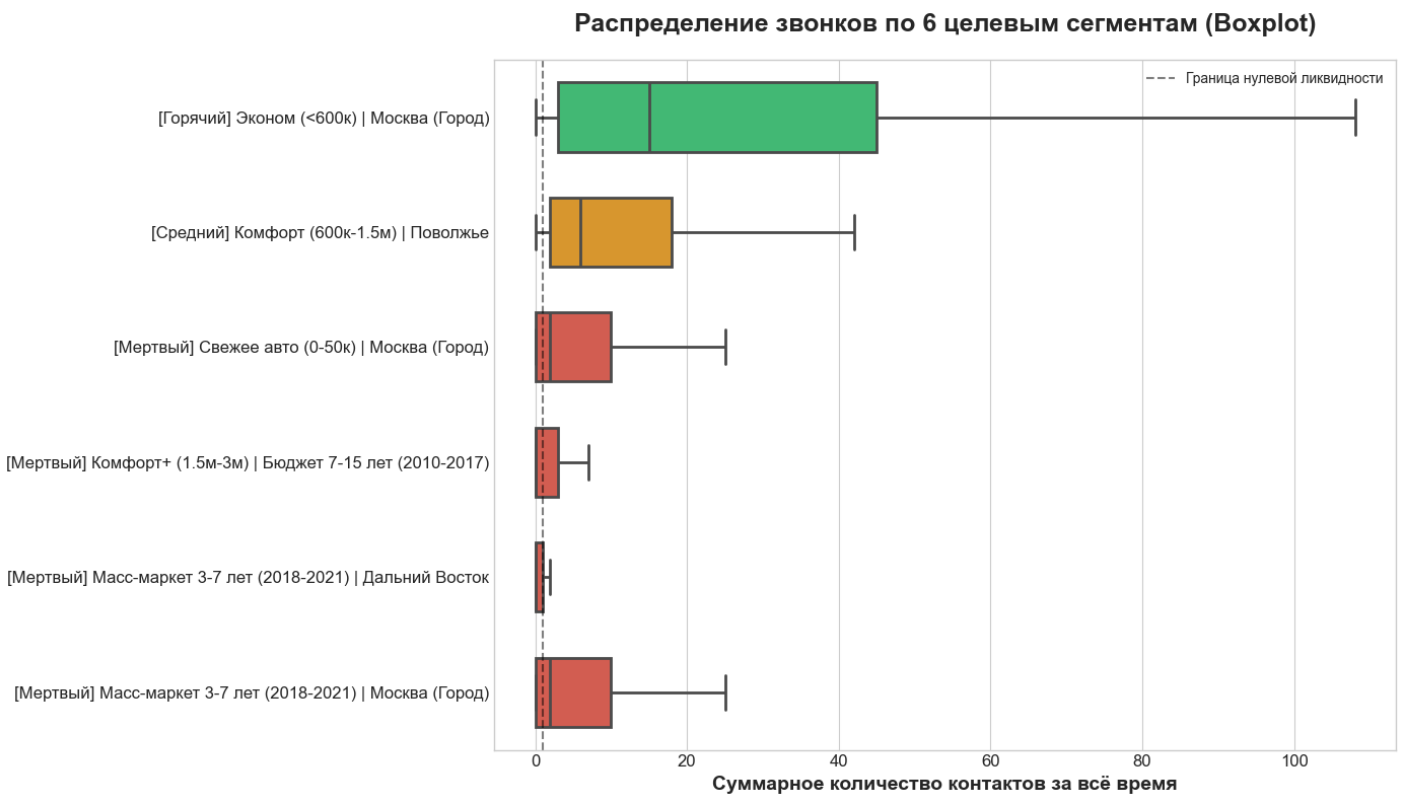

Горячий сегмент (Зеленый ящик): широкий и сильно растянут вправо. Это значит, что 50% основной массы (межквартильный размах) продавцов получают от 5 до 20 звонков стабильно. Предлагать им VAS — это сжигать лояльность пользователей, они и так успешны

Мертвые сегменты (Красные ящики): 'коробки' буквально сплющены и прижаты к нулю. Левый ус и медиана лежат на нуле. Это означает, что большинство продавцов в этих сегментах не получают вообще ни одного звонка. Это не просто среднее значение упало из-за пары плохих авто, это системная глухота рынка в этих нишах. Именно сюда мы направляем фокус наших алгоритмов монетизации (VAS) с первого же дня!

NOTEBOOK 3 | ИНСАЙД

Макроэкономические аномалии: слепая зона Дальнего Востока

При живой базе в **5000+ машин** количество органических контактов стремится к нулю. Это не баг данных, это не ошибка парсинга. Это **монополия Drom.ru** на этой территории — они захватили рынок японских авто на Дальнем Востоке еще до появления Авито.

Как мы это нашли

Алгоритм кластеризации автоматически выделил сегмент с нулевой ликвидностью. Мы проверили: это не техническая ошибка, а **реальная рыночная реальность**. Географическая изоляция + специфика японских аукционов = доминирование нишевого игрока.

Бизнес-интервенция

Предлагаем **агрессивный демпинг**: бесплатный VAS на 6 месяцев для всех японских авто на Дальнем Востоке. Цель — отвоевать долю рынка у Drom.ru. Стоимость: ~2 млн ₽. Потенциальный эффект: +15% инвентаря в регионе.

5000+	0	6 мес	+15%
Машин в сегменте	Звонков в день	Бесплатный VAS	Потенциал роста

ВИЗУАЛИЗАЦИЯ 1 | HEATMAP

Тепловая карта выгорания: 3 дня vs 3 недели

Нормализованный спрос по дням и сегментам

Высокий Средний Низкий

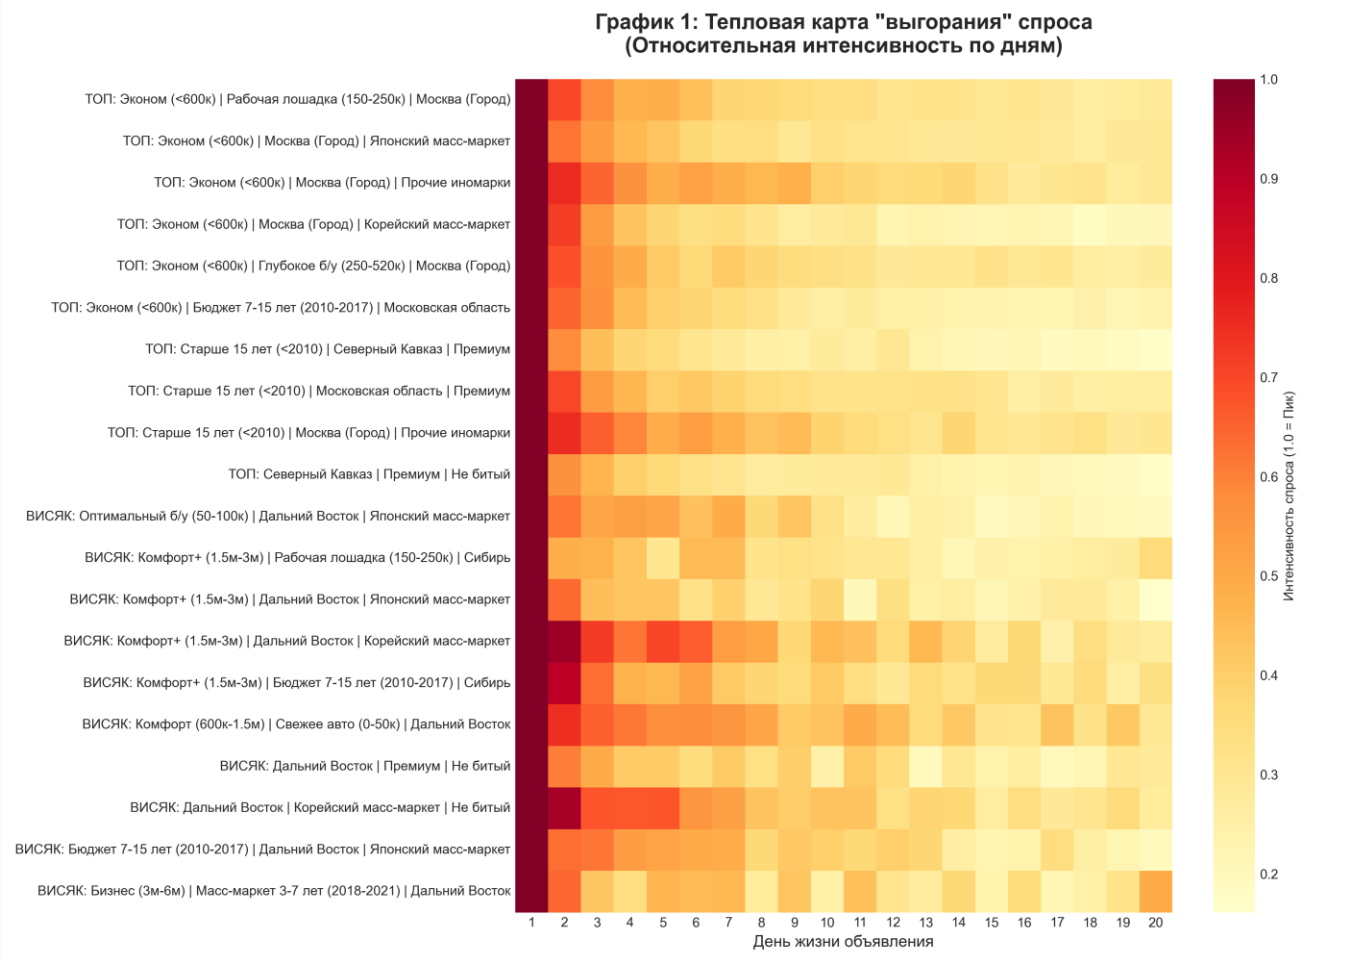

Топовые машины

Интерес **выгорает за 3 дня**. Красная зона резко обрывается — после пика спрос падает на 80%. Это не постепенное угасание, это обрыв.

Средние машины

Спрос размазан на **7-14 дней**. Синяя зона тянется равномерно, без резких пиков. VAS нужен, но не срочно.

Висяки

Спрос размазан **тонким слоем на 3 недели**. Зеленая зона — почти равномерное отсутствие интереса. Это зона максимальной боли продавца.

ВЫВОД

Разным машинам нужен **разный триггер для VAS**. У топовых — сразу после пика, у висяков — через 10+ дней молчания.

Смерть Random Forest: почему классика не работает

Random Forest провалился

Проблема 1: Усреднение пиков

RF предсказывает среднее значение, игнорируя тяжелый правый хвост. Для редких событий (0-1-2 звонка) это катастрофа.

Проблема 2: Нули не предсказываются

Модель не умеет предсказывать нулевой спрос. А это 30-40% случаев! Для бизнеса ноль звонков — самый важный сценарий.

Проблема 3: MSE не подходит

Квадратичная ошибка штрафует выбросы слишком агрессивно. Для счетных данных это искажает оптимизацию.

LightGBM + Poisson

Решение: Poisson Loss

Перешли на **LightGBM с objective='poisson'**. Функция потерь математически заточена под закон распределения редких счетных событий.

Преимущество: Нативная работа с нулями

Poisson distribution моделирует вероятность нулевых событий корректно. Модель понимает, когда звонков не будет.

Бонус: Скорость и масштабируемость

LightGBM в 10+ раз быстрее Random Forest на наших данных. Обучение на 2 млн объявлений — менее 5 минут.

RF	LGBM	Poisson	5 мин
Не работает	Работает	objective	Обучение

SHAP: от черного ящика к прозрачной логике

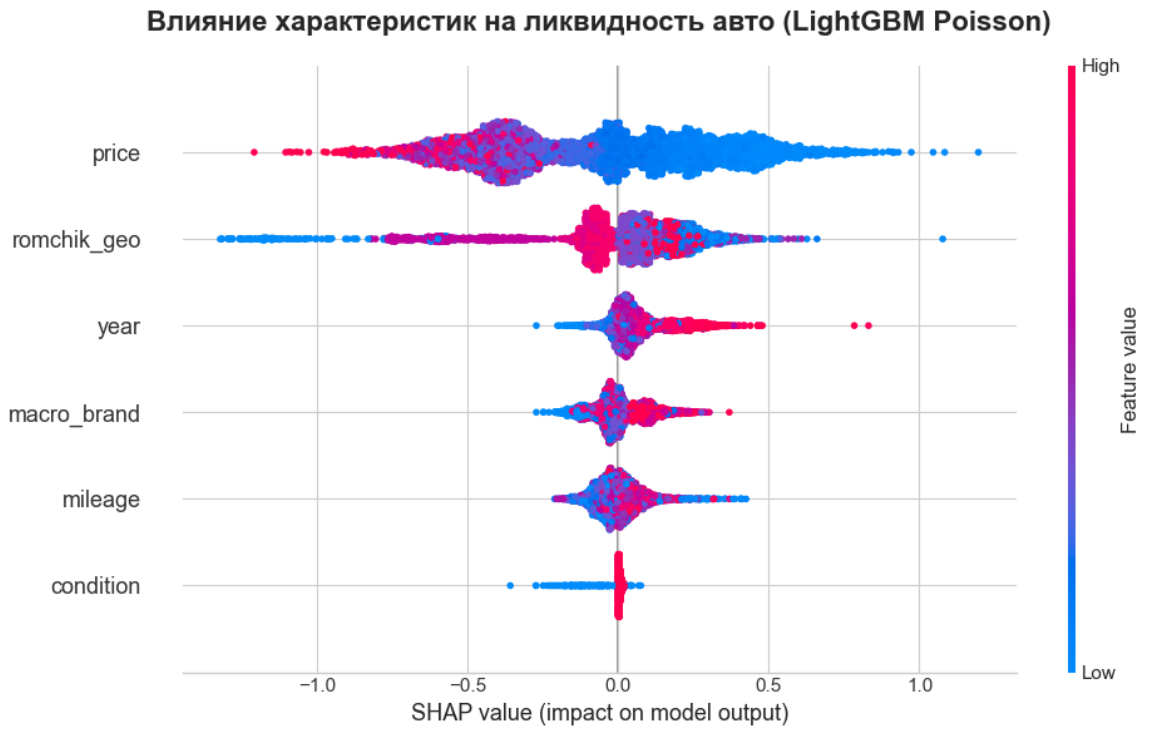

Summary Plot (Beeswarm). Это самый наглядный график. Он показывает:

- Какие фичи самые важные (ранжирование сверху вниз).
- Как значение фичи (высокое/низкое — цвет) влияет на таргет (сдвиг влево/вправо).

Каждая точка — это один объект (объявление/пользователь)

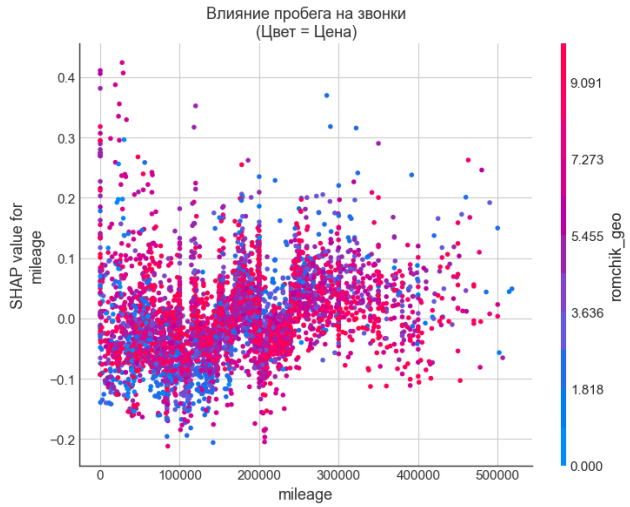

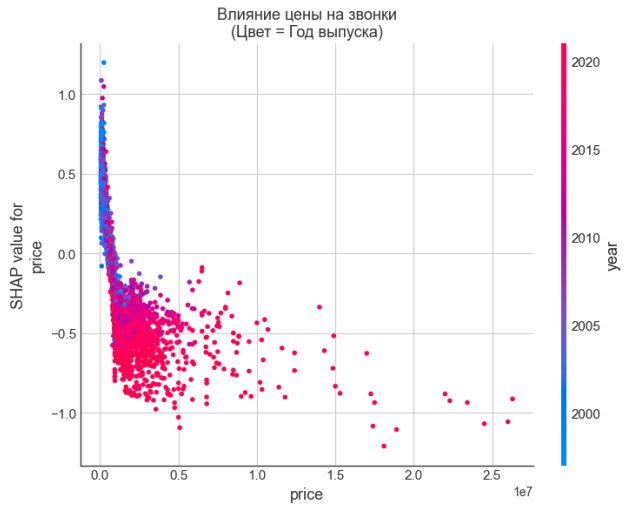

БИЗНЕС-ОЦЕНКА ML МОДЕЛИ

Не MAE, Recall: бизнесу плевать на 1.2 звонка

Почему MAE не важен

Бизнесу не интересна регрессионная ошибка в "1.2 звонка". Важно другое: **когда мы шлем пуш — действительно ли машине нужен VAS?** Если модель говорит "нужен", а машина продастся сама — это каннибализация. Если модель говорит "не нужен", а машина зависнет — это отток.

Конверсия в классы

Перевели предсказания регрессора в бинарные классы:

- **Красная зона = 0 звонков** (Мертвая зона. VAS с 1-го дня.)
- **Оранжевая зона = 1–19 звонков** (Средний класс. Нужен буст на 5-7 день.)
- **Зеленая зона = 20+ звонков** (Органика бьет ключом. Не трогаем.)

Метрики Recall

Считаем **Recall для Красной зоны**:

Бизнес-фокус: Каждое авто в «красном ящике» — это горячий лид на покупку продвижения.

Итог: Максимизируя Recall, мы гарантируем максимальный охват целевой аудитории и расширяем воронку продаж VAS.

19.4%	56.1%	<5%	0.79
“Мертва” доля рынка	“Оранжевая” доля рынка	Ложные пуши	F1-score

ВНЕДРЕНИЕ | A/B ТЕСТ

Сплит-тест по юзерам: динамическая модель задержки пушей

Методология

Сплит-тест по юзерам

50/50 разделение новых объявлений. Контроль — базовая логика пушей Авито. Тест — наша динамическая модель задержки.

Длительность: 4 недели

Минимальный цикл для сбора статистически значимой выборки (>10k объявлений в каждой группе).

Механика: динамическая задержка

Модель предсказывает ликвидность и решает: пушить сразу, через 5 дней, 20 дней или не стоит предлагать вовсе. Каждому сегменту — свой триггер.

Метрики (OEC)

Primary: ARPU

Рост выручки с платных услуг на одного пользователя. Цель: **+15-20%** к базовому уровню.

Secondary: Конверсия

Конверсия в контакт после применения VAS. Проверяем, что пуши реально помогают продавать.

Guardrail: Отписки

Процент отписок от пуш-уведомлений. **Красная линия: <2%** роста относительно контроля.

ПЛАН ВНЕДРЕНИЯ

Неделя 1-2: пилот на 5% трафика. Неделя 3-4: расширение до 50%. Неделя 5: анализ, корректировка модели. Неделя 6: полный rollout при положительных метриках.

ЭЛИТНЫЙ ГАРАЖ АВИТО

Монетизация ретро-рынка и Янгтаймеров

Как перейти от разовых продаж к долгим подпискам в сегменте B2B и коллекционеров

1. Математика рынка

- **Плоский спрос:**
Ретро-авто ищут месяцами. Суточные бусты сжигают бюджет продавца.

- **Инвестиционный бум:**
Главный очаг спроса — идеальные авто 80-х дороже 5 млн руб.

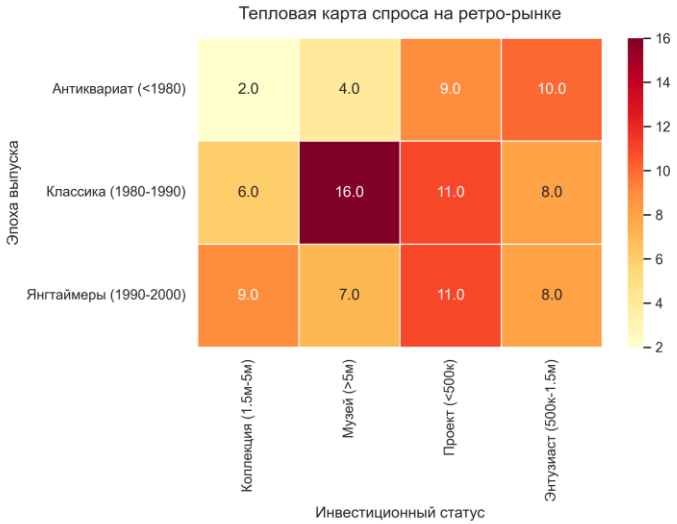

2. Новые продукты Авито

- **Отказ от суточных тарифов:**
Отключаем предложение «X10 просмотров» для машин старше 25 лет.

- **Умные бейджи:**
Алгоритмическая плашка «Капсула времени» для премиум-авто с пробегом <50к.

- **Ввод «Ретро-подписки»:**
Длинный тариф на 30/60 дней для удержания объявления в топе коллекционной витрины.

- **Гео-Таргетинг:**
Вывод 80-х годов в рекомендации для Москвы, а машин до 80-го года — для Питера.

3. Бизнес-профит

Высокий LTV: Цикл сделки в 10 раз дольше, продавец покупает подписку несколько раз.

Премиальное ценообразование: B2B-аудитория не чувствительна к цене. Статус эксклюзива позволяет кратно повысить чек на VAS-услуги.

Магнит трафика: Ретро-авто работают как виральный контент. Репосты уникальных лотов увеличивают общее время на платформе и показы рекламы.

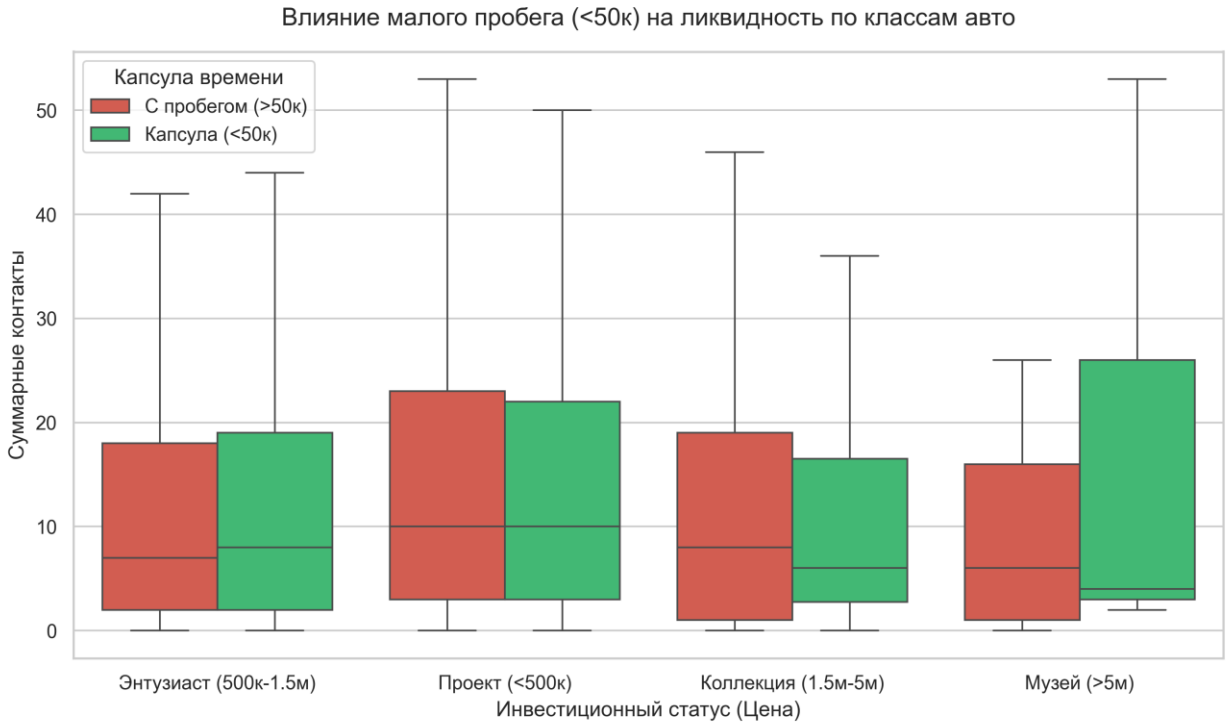
Влияние малого пробега (<50к) на ликвидность по классам авто
Капсула времени
С пробегом (>50к)
Капсула (<50к)
Суммарные контакты
0
10
20
30
40
50
Энтузиаст (500к-1.5м)
Проект (<500к)
Коллекция (1.5м-5м)
Музей (>5м)
Инвестиционный статус (Цена)

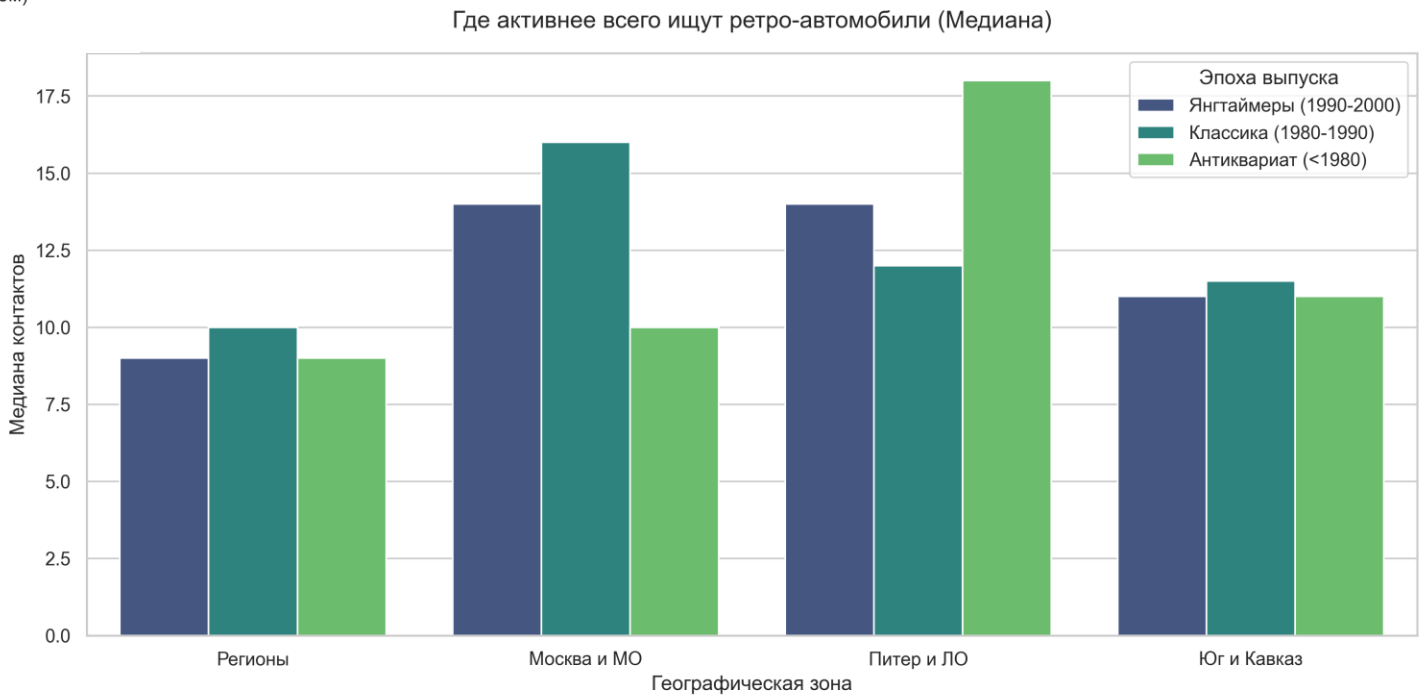
Где активнее всего ищут ретро-автомобили (Медиана)
Эпоха выпуска
Янгтаймеры (1990-2000)
Классика (1980-1990)
Антиквариат (<1980)
Медиана контактов
0.0
2.5
5.0
7.5
10.0
12.5
15.0
17.5
Регионы
Москва и МО
Питер и ЛО
Юг и Кавказ
Географическая зона

Кто мы?

Кронверкские псы

- Cup IT 2026 “Аналитика данных ” – 1 место
- Нефтекод 2026 - Финал

Корняков Роман
НИУ ИТМО 1 Курс
Аналитик/стратег

Фёдоров Арсений
НИУ ИТМО 1 Курс
Аналитик/ML

Позин Михаил
НИУ ИТМО 1 Курс
Риск-Аналитик

Ильенков Матвей
НИУ ИТМО 1 Курс
Аналитик/исследователь ресурсов

Приложение 1:
Наша аналитика основана на работе с датасетом, предлагаем вам ознакомится с нашим пайплайном, который приложен вместе с презентацией, там можно ознакомится с дополнительными визуализациями и тонкостями работы. QR-код на github в приложении 2

1_EDA.ipynb

2_Feature_Licvid.ipynb

3_Segmentation.ipynb

RETRO.ipynb

Приложение 2